# Regressão logística multinomial com taxa de aprendizado dinâmica

Utilizando o método da bisecção

```
In [1]:
using Revise
using CSV, DataFrames, Plots, Distributions, LinearAlgebra

In [2]:
include("../src/reglog.jl")

Out[2]:
Main.RegLog

In [3]:
using .RegLog
```

# **Dados**

3

```
In [4]:
X, Y = readiris("../data/raw/iris.m")
X = hcat(X, ones(size(X)[1]))
Y_m = preparey(Y)
Out[4]:
150×3 Matrix{Float64}:
 1.0 0.0 0.0
     0.0
 1.0
          0.0
 1.0
     0.0
          0.0
 1.0 0.0 0.0
 1.0
     0.0
          0.0
 1.0
     0.0
          0.0
 1.0
     0.0
          0.0
 1.0
     0.0
          0.0
     0.0
 1.0
          0.0
 1.0
     0.0
          0.0
 1.0
     0.0 0.0
 1.0
     0.0 0.0
 1.0
     0.0
          0.0
 0.0
      0.0
          1.0
      0.0
 0.0
          1.0
 0.0
     0.0
          1.0
 0.0
     0.0
          1.0
 0.0
     0.0
          1.0
 0.0
     0.0
          1.0
 0.0
     0.0
          1.0
 0.0
     0.0 1.0
 0.0
     0.0 1.0
 0.0 0.0 1.0
     0.0
 0.0
          1.0
 0.0
     0.0 1.0
In [5]:
n, \mathcal{D} = size(X) # numero de instancias e features
k = size(Y_m)[2] # numero de classes
Out[5]:
```

# Regressão multinomial sem e com bisseção

A implementação direta da softmax pode ser dada pelo algoritmo abaixo:

#### In [6]:

```
function cross_entropy(Ym, Ŷ)
  -sum(Ym .* log.(Ŷ))
end
```

#### Out[6]:

cross entropy (generic function with 1 method)

#### In [7]:

```
function simple_softmaxregression(X, Y)
     \theta = rand(k, D)
                            # inicializa a matriz de coeficientes
     \hat{Y} = softmax(X * \theta') # calcula as probabilidades de cada classe
     \nabla = (\hat{Y} - Y_m)' * X # calcula o vetor gradiente \nabla_n = \nabla/\text{norm}(\nabla) # normaliza o gradiente para itmax = 1000 # numero maximo de iterações
                                   # normaliza o gradiente para um passo unitário
                                   # taxa de aprendizado fixa
     \eta = 3e-1
     \epsilon = 1e-2
     it = 0
     losses = Vector()
     while (norm(\nabla) > \epsilon) & (it < itmax)
           it += 1
           \hat{Y} = softmax(X * \theta')
           \nabla = (\hat{Y} - Y_m)' * X
           \nabla_n = \nabla/\text{norm}(\nabla)
           \theta = \theta - \eta * \nabla_n
           loss = cross entropy(Y_m, \hat{Y})
           push!(losses, loss)
     end
     return \theta, losses
end
```

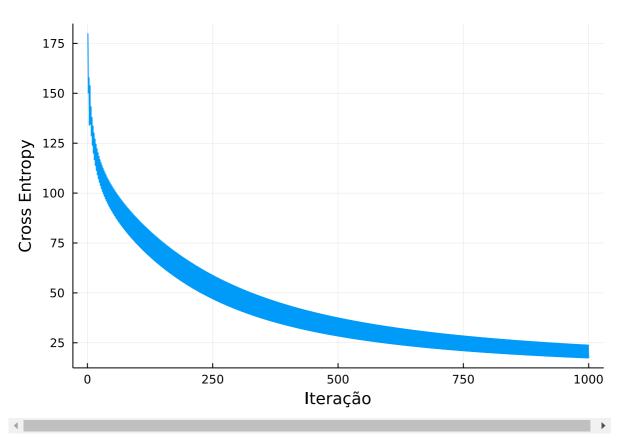
#### Out[7]:

simple softmaxregression (generic function with 1 method)

#### In [8]:

```
simple_{\theta}, simple_{loss} = simple_{softmax} regression(X, Y_m) plot(<math>simple_{loss}, xlabel="Iteração", ylabel="Cross Entropy", legend=false)
```

#### Out[8]:



No entanto, para otimizar a convergência do algorítmo, podemos utilizar o método de bissecção baseado em algumas premissas e proposições. \

Primeiro inicializaremos novamente os parâmetros da softmax:

#### In [9]:

```
\begin{array}{lll} \theta = \text{rand}(k,\,\mathcal{D}) & \# \text{ inicializa a matriz de coeficientes} \\ \hat{Y} = \text{softmax}(X \, * \, \theta') & \# \text{ calcula as probabilidades de cada classe} \\ \nabla = (\hat{Y} \, - \, Y_\text{m})' \, * \, X & \# \text{ calcula o vetor gradiente} \\ \nabla_\text{n} = \nabla/\text{norm}(\nabla) & \# \text{ normaliza o gradiente para um passo unitário} \\ \text{itmax} = 1000 & \# \text{ numero maximo de iterações} \\ \eta = 3\text{e-}1 & \# \text{ taxa de aprendizado fixa} \\ \varepsilon = 1\text{e-}2 \\ \text{it} = 0 & \end{array}
```

# Out[9]:

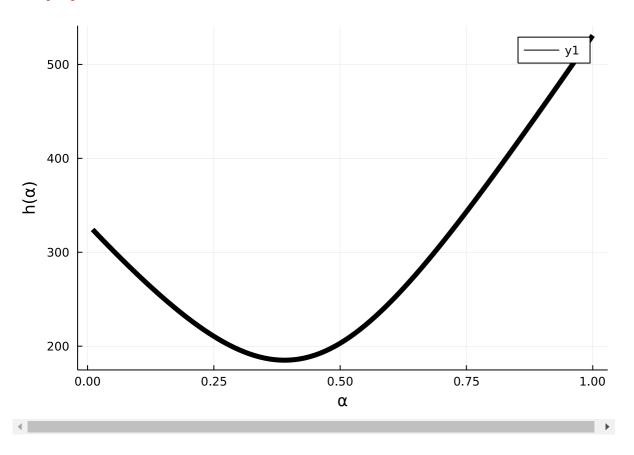
0

Podemos notar após esta primeira iteração que h(a) é uma função convexa:

#### In [10]:

```
alphas = cumsum(zeros(100) .+ 0.01)  
hs = Vector()  
for a in alphas  
   push!(hs, h(a, \theta, \nabla_n, X, Y_m))  
end  
plot(alphas, hs, linewidth=5, color=:black, xlabel="\alpha", ylabel="h(\alpha)")
```

### Out[10]:

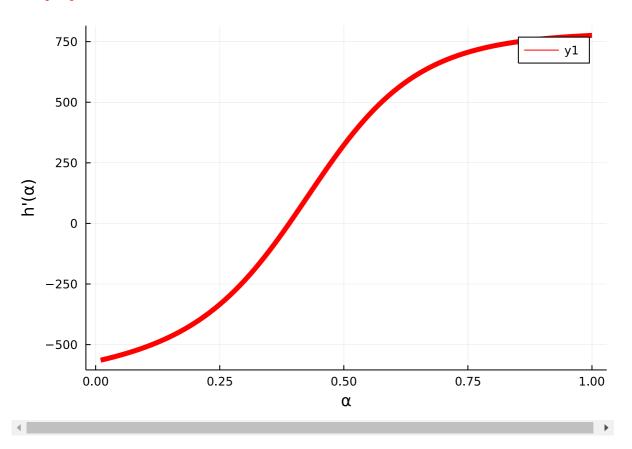


E sendo convexa, sabemos que a proposição h'(0) < 0 é verdadeira, como demonstrado:

#### In [11]:

```
hls = Vector()
for a in alphas
    push!(hls, ĥ(a, θ, ∇n, X, Ym))
end
plot(alphas, hls, linewidth=5, color=:red, xlabel="α", ylabel="h'(α)")
```

#### Out[11]:



Sabendo disso, podemos aplicar o método da bisecção escolhendo:

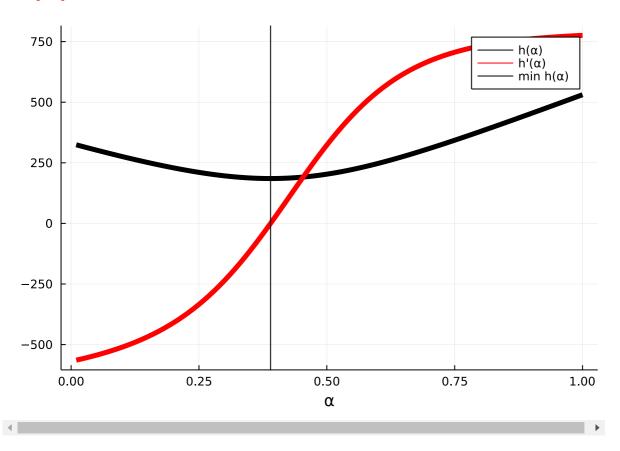
- $\alpha I = 0$
- $\alpha u = o$  primeiro  $\alpha$  aleatório cuja  $h'(\alpha) > 0$

Podemos ainda verificar que quando h'(a) tende a 0 o valor de h(a) tende ao mínimo global

#### In [12]:

```
plot(alphas, hs, linewidth=5, color=:black, xlabel="\alpha", label="h(\alpha)") plot!(alphas, hls, linewidth=5, color=:red, xlabel="\alpha", label="h'(\alpha)") vline!([alphas[argmin(hs)]], color=:black, label="min h(\alpha)")
```

#### Out[12]:



Logo, basta adicionarmos o algoritmo de bissecção para encontrar um  $\alpha$ , que minimize a loss function na iteração atual.

#### In [13]:

```
function bisection softmaxregression(X, Y)
                             # inicializa a matriz de coeficientes
     \theta = rand(k, \mathcal{D})
     \hat{Y} = softmax(X * \theta') # calcula as probabilidades de cada classe
     \nabla = (\hat{Y} - Y_m)^{\top} * X # calcula o vetor gradiente

\nabla_n = \nabla / \text{norm}(\nabla) # normaliza o gradiente para um passo unitário
     itmax = 1000
                                   # numero maximo de iterações
     \epsilon = 1e-2
     it = 0
     losses = Vector()
     while (norm(\nabla) > \epsilon) \& (it < itmax)
           it += 1
           \hat{Y} = softmax(X * \theta')
           \nabla = (\hat{Y} - Y_m)' * X
           \nabla_n = \nabla/\text{norm}(\nabla)
           \eta = bisection(\theta, \nabla_n, X, Y_m)
           \theta = \theta - \eta * \nabla_n
           loss = cross entropy(Y_m, \hat{Y})
           push!(losses, loss)
     end
      return \theta, losses
end
```

#### Out[13]:

bisection softmaxregression (generic function with 1 method)

#### In [14]:

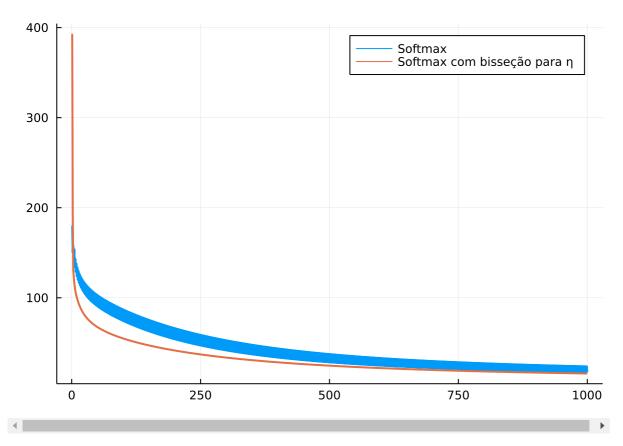
```
bisec_\theta, bisec_loss = bisection_softmaxregression(X, Y<sub>m</sub>)
```

#### Out[14]:

# In [17]:

```
plot(simple_loss, linewidth=2, label="Softmax")
plot!(bisec_loss, linewidth=2, label="Softmax com bisseção para η")
```

## Out[17]:



# In [ ]: